Physical AI 応用編1（2026）最終課題：SO-101 による耳栓のピック＆プレース

1. タイトル・アカウント

- タイトル：SO-101 による耳栓のピック＆プレース（ACT）
- omnicampus アカウント名：Beachcities

2. 課題の概要

- 何を：SO-101 の実機で「録画 → 学習 → 実機推論」を一周させる。
- タスク：黄色の耳栓をつまみ、青いテープの芯の中心へ入れる（タスク文字列 `Pick up the yellow earplug and put it into the blue tape core.`）。
- 耳栓は A4 の紙に印を付けた 5 か所のどれかに置き、テープの芯は紙の上の決まった位置に固定する。

3. 目的

- 模倣学習（ACT）の方策を自分で録ったデータで学習し、実機でピック＆プレースを成功させる。
- 置き場所ごとの成功・失敗を数え、うまくいかない理由を自分のデータで説明する。

4. システム構成

4.1 ハードウェア

部品	内容
アーム	SO-101（リーダー：黒、フォロワー：白）
カメラ	Logicool C920 1 台（斜め上から作業面を見る。640×480、30 fps）
実機の PC	Ubuntu 22.04、RTX 4070 Laptop GPU（8 GB）
学習	同じ PC の GPU

4.2 ソフトウェア

部品	版・内容
LeRobot	0.4.4
方策	ACT（`--policy.type=act`、学習済みの重みは使わず最初から学習）
自作のスクリプト	`record/record_so101.sh`、`record/lerobot_record_keys.py`、`scripts/camera_lock.sh`、`scripts/inspect_dataset.py`、`scripts/offline_eval.py`、`train/train_act_local.sh`

4.3 データの流れ

```
リーダーで操作 → record/record_so101.sh main（lerobot-record）
  → データセット beachcities/so101-pickplace-v2（Hugging Face Hub、private）
  → train/train_act_local.sh（lerobot-train、ACT、このPCのGPU）
  → 方策 beachcities/act_so101_pickplace_v2（Hub、private）
  → scripts/offline_eval.py（録画のデータで答え合わせ。アームは動かさない）
  → record/record_so101.sh eval（lerobot-record に方策を渡して実機で推論）
```

5. データ

項目	値
データセット名	beachcities/so101-pickplace-v2（private）
エピソード数	50（置き場所 5 か所 × 10）
フレーム数・fps	20839 フレーム、30 fps（1 本 8.1〜30.5 秒、平均 13.9 秒）
カメラ	1 台（front）
タスク文字列	Pick up the yellow earplug and put it into the blue tape core.
置き方の変化	耳栓の置き場所 5 か所（紙の印）。テープの芯の位置は固定。開始姿勢は毎回同じ
場所ごとのつかみ方	場所 4（台から一番遠い）だけ、手先を約 180° 返してつかむ（次の段落）

場所 4 は台から一番遠く、そのままの向きだとリーダーの先が机に当たってフォロワーが真似しにくかった。手先を返すと、フォロワーのくちばしの長い側が奥になり、引っかからずにつかめる。そこで場所 4 だけは「開始姿勢 → 近づく途中で手先を返す → つかむ → 入れる → 手先を戻して開始姿勢」とした。手首の回転の値（返すと約 0°、返さないと約 +167°）で、場所 4 の 10 本ともそうなっていることを確かめた。

データの検査は scripts/inspect_dataset.py で行った（本数・タスク文字列・動画のフレーム数が total_frames と一致・動画が最後まで開けること）。途中で外したエピソードは 5.1 に書く。

5.1 録り直したもの

内容	対応
白いアームの台のバークランプが外れた	それまでの 3 本（v1）を使わず、v2 として 1 本目から録り直した
場所 4 の最初の 10 本は、つかみ方が途中で変わり、開始姿勢も手先を返した状態だった	10 本を外して（lerobot-edit-dataset の delete_episodes）録り直した
場所 4 の録り直しの 1 本目は手先を返さず、手首の値が ±180° をまたいで跳ねていた	1 本を外して録り直した

6. 学習

項目	ACT
初期の重み	なし（最初から学習）
step 数・バッチ	100000 step、batch 8（約 800K サンプル、データセット約 38 周）
学習の時間	4 時間 1 分（RTX 4070 Laptop、1 step 約 0.145 秒、GPU 使用率 98〜99%）
保存	5000 step ごと（20 個）。方策は Hub に private で保存
パラメータ数	51.7M

ロスの下がり方：

step	1K	5K	10K	20K	40K	60K	80K	100K
ロス	1.940	0.396	0.174	0.101	0.063	0.049	0.042	0.038

6.1 実機の前の答え合わせ

実機で動かす前に、`scripts/offline_eval.py` で、録画の映像と関節の値を推論と同じ順で 1 フレームずつ方策に見せ、方策が出す動きと記録の動きを比べた（場所ごとに 2 本、計 10 本）。

	pan	lift	elbow	wrist_flex	wrist_roll	gripper
方策と記録の平均の差（度）	1.0	1.5	1.8	2.4	0.9	0.8
目安：最初の姿勢のまま動かない場合	16.3	57.3	48.8	123.9	20.1	9.8

つかんで離す動き（グリッパーの閉じと開き）と、場所 4 で手先を返す動き（手首の回転の最小 4.4° / 記録 7.5°）も再現していた。ただし、これは学習に使ったデータでの確認で、実機で動くことの保証ではない。

7. 結果

実機での推論（`record/record_so101.sh eval`、場所ごとに 3 回、1 回 60 秒まで）。

置き場所	結果	成功
1	○○○	3/3
2	○○○	3/3
3	×××	0/3
4（手先を返す）	×○×	1/3
5	×○×	1/3
計		**8/15（53%）**

- 場所 1 では、成功のあとに耳栓を置き直すと、方策がもう一度つかんで入れた（1 回の 60 秒の中で 5 回入れた）。
- これより前の 1 回目の推論（場所 1・2 のみ）では、18 回試して 11 回成功だった。

失敗の型

型	回数	様子
位置が左にずれる	3（場所 3）	耳栓 1 個分、左にずれたところへ降りる
下まで降りない・手先を返さない	2（場所 4）	2 回目からは左にずれ、手先も返さなかった
手先を 90° ひねる	2（場所 5）	返さずに取れる位置なのに、手先を約 90° ひねった

8. 工夫した点・苦労した点（サンプルからの発展）

8.1 工夫した点

- **Wayland の画面で録画のキー操作を使えるようにした。** LeRobot の録画は → ← Esc（pynput）で進めるが、Ubuntu の既定の画面（Wayland）ではキーが届かなかった。`record/lerobot_record_keys.py` で、キーを「コマンドを実行したターミナル」から直接読むようにし、Enter で次へ、Backspace で録り直し、Esc でやめる、にした。LeRobot 本体は書き換えず、起動のしかたで置き換えている。
- **録画と動きがずれない仕組み。** 保存中に押した Enter が次に持ち越されて次の録画が 0 秒で終わる問題があったので、区間が始まる前のキーを捨て、2 秒以内の 2 回目も捨てるようにした。起動直後にすぐ録画が始まらないよう「準備」の区間を入れ、画面には区間が実際に始まった瞬間に「いま Enter で N 回目（場所 X）」などを出した。
- **置き場所ごとの記録。** 何本目がどの場所かを CSV に残し、場所 1 を 10 本 → 場所 2 を 10 本 … の順で案内した。
- **場所に応じたつかみ方。** SO-101 のくちばしの形に合わせ、場所 4 だけ手先を返してつかむようにし、開始姿勢は全部同じにそろえた。手首の値でそろっていることを確かめ、そろっていない回は外して録り直した。
- **カメラの条件をそろえた。** `/dev/video0` が内蔵カメラだったので C920 を固定のパスで指定した。ピント・露出・ホワイトバランスの自動調整を切って値を固定し（`scripts/camera_lock.sh`）、録画のたびに同じ値を設定し直した。作業面のまわりの物を片付け、A4 の紙全体とアームの肩・肘が入る画角にした。
- **実機の前に答え合わせをした**（6.1）。
- **推論の安全。** 推論では 1 回の指令で動ける角度に上限（`max_relative_target=40`）を付けた。録画の記録で、普通の動きの指令と実際の位置の差が手首の曲げで上位 1% 38° だったので、普通の動きを妨げない値にした。

8.2 苦労した点

- Wayland ではキーが届かないことに気づくまでに時間がかかった。X11 の窓を開いてそこを選んでもらう方法も試したが、小さい画面で窓の選択が外れるとキーが届かなくなり、ターミナルから読む方法に落ち着いた。
- キーのずれ（保存中の Enter の持ち越し、押しっぱなし防止の誤動作）で、録画の区間と実際の動きがずれ、何度も録り直した。

- 白いアームの台のバークランプが外れ、それまでのデータを捨てて 1 からやり直した。
- 場所 4 のつかみ方を途中で変えたため、その場所の 10 本を録り直した。

8.3 サンプルとの違い

- LeRobot の SO-101 の手順（`lerobot-record` → `lerobot-train --policy.type=act` → 方策で `lerobot-record`）を土台にした。
- 変えた点：自分で決めたタスク（耳栓とテープの芯、5 か所の置き場所）、場所 4 だけのつかみ方、Wayland で動くキー操作と案内（8.1）、カメラの固定、データの検査と不良エピソードの削除、録画のデータでの答え合わせ、推論の上限の設定。

9. 反省点・考察

- **場所によって成功率がはっきり違った**（場所 1・2 は 3/3、場所 3 は 0/3）。録画のデータでの答え合わせでは、場所 3 も他と同じくらい再現できていた（全関節の平均の差 1.2°）。実機で少しずれたときに立て直せていないと考える。
- **明るさの違い**：録画は昼（13〜14 時、窓からの光）で、推論は夜（19 時台、室内の照明）だった。画面の明るさの平均は、録画が 153〜175、推論が 108〜110（0〜255）で、色も橙色に寄っていた。カメラの露出を昼の値で固定していたので、夜は画面が暗くなった。カメラの位置のずれは数画素で、原因ではないと確かめた。場所 3・4 がどちらも左にずれたのは、明るさや影の違いで位置を読み違えた可能性がある（推測）。
- **場所 4 のつかみ方が場所 5 に混ざった可能性**：場所 5 で手先を約 90° ひねったのは、場所 4 の「180° 返す」と場所 5 の「返さない」の中間に見える。似た場面で手本の動きが割れていると、ACT が中間の動きを出すことがある。場所 4 の印を台に近い側へ移し、返さずに取れる位置にすれば、手順を 1 つにそろえられた。
- 1 か所あたり 10 本は少なかった。成功率の低い場所を録り足すこと、録画と推論の明るさをそろえることが次の改善になる。
- 数か月ぶりに実機を触ったのに、準備（慣らし・片付け・置き方）を飛ばして録画を始め、やり直しが増えた。録画の前に、テレオペで慣らし、画角と置き方を決める時間を取るべきだった。

10. リンク

- GitHub：https://github.com/beachcities/pai2026-advance1-final
- YouTube（動画）：https://youtu.be/9_KTuG4R2Bg（等速、1 分 47 秒）